TECNOLÓGICO NACIONAL DE MÉXICO

DEPARTAMENTO DE SISTEMAS Y COMPUTACIÓN

Ingeniería en Sistemas Computacionales

Asignatura: Fundamentos de Ciencia de Datos

Actividad Integradora: Evaluación Práctica de la Unidad 2

Inferencia Estadística y Toma de Decisiones en Ingeniería

Modalidad: Equipos
Entregables requeridos: cuaderno `.ipynb` ejecutable y Reporte Técnico en PDF.

1. Objetivo y Metodología de Elaboración

Aplicar técnicas de estadística descriptiva, simulación del Teorema Central del Límite, estimación mediante intervalos de confianza y pruebas de hipótesis paramétricas sobre un escenario de ingeniería de software o infraestructura tecnológica, empleando el lenguaje de programación **Python** (`numpy`, `pandas`, `matplotlib`, `seaborn`, `scipy`) para sustentar una decisión técnica formal.

2. Casos de Estudio Disponibles

Cada equipo debe seleccionar **un único caso** de la siguiente lista:

- **Caso A: Arquitectura de Software (Monolito vs. Microservicios)**
  - *Problema:* Determinar si la sobrecarga de red en microservicios incrementa la latencia respecto a un monolito.
  - *Variable cuantitativa (Y):* Latencia de respuesta HTTP en milisegundos (ms).
  - *Variable cualitativa (X):* Tipo de arquitectura (`Monolito` vs. `Microservicios`).
- **Caso B: Motores de Base de Datos (PostgreSQL vs. MongoDB)**
  - *Problema:* Contrastar si existe diferencia en el tiempo de procesamiento de transacciones mixtas entre un motor relacional y uno documental.
  - *Variable cuantitativa (Y):* Tiempo de ejecución por transacción en milisegundos (ms).
  - *Variable cualitativa (X):* Motor de base de datos (`PostgreSQL` vs. `MongoDB`).
- **Caso C: DevOps y Calidad de Código (Tiempos de Integración CI/CD)**
  - *Problema:* Validar si la implementación de flujos de prueba automatizados reduce el tiempo de aprobación y cierre de Pull Requests.
  - *Variable cuantitativa (Y):* Tiempo de integración en horas.
  - *Variable cualitativa (X):* Pipeline (`Con_CI` vs. `Sin_CI`).
- **Caso D: Redes y Sistemas Embebidos (Protocolo HTTP vs. MQTT)**
  - *Problema:* Analizar si la transmisión periódica de telemetría en dispositivos IoT consume significativamente menos memoria RAM con MQTT en comparación con HTTP/REST.

- *Variable cuantitativa (Y):* Uso de memoria RAM por ciclo de transmisión en kilobytes (KB).
- *Variable cualitativa (X):* Protocolo (`HTTP` vs. `MQTT`).

3. Obtención y Criterios del Dataset

El conjunto de datos debe contar con un tamaño muestral de al menos **200 observaciones por grupo** ($N \geq 400$ registros en total), debiendo almacenarse en formato `.csv` dentro del directorio `data/` del repositorio.

Fuentes permitidas:

1. **Repositorios abiertos:** Kaggle (búsquedas: *API latency logs*, *server performance*) o el UCI Machine Learning Repository (*Computer Hardware*, *Firewall Data*).
2. **Extracción directa:** Extracción por API REST de GitHub o telemetría de pruebas de carga locales (`Apache Bench` o `Locust`).
3. **Generación sintética justificada:** Si no se dispone de un dataset público, se puede simular en Python mediante distribuciones teóricas:

```python
import numpy as np
import pandas as pd

np.random.seed(42)
n = 250

lat_monolito = np.random.gamma(shape=2.5, scale=35, size=n) + 40
lat_microserv = np.random.gamma(shape=2.2, scale=40, size=n) + 45

df = pd.DataFrame({
    'latencia_ms': np.concatenate([lat_monolito, lat_microserv]),
    'grupo': ['Monolito'] * n + ['Microservicios'] * n
})
df.to_csv('data/dataset_caso_a.csv', index=False)
```

Listing 1: Script base para generación paramétrica (Caso A)

4. Problemas Específicos a Resolver

Bloque 1: Estadística Descriptiva y Limpieza

1. Cargar el dataset en un `DataFrame` de Pandas y verificar tipos de datos y valores ausentes.
2. Detectar y remover valores atípicos (*outliers*) empleando el criterio del rango intercuartílico (1,5×IQR).
3. Calcular para ambos grupos: media muestral ($\bar{x}$), mediana, desviación estándar (s), varianza (s^2), asimetría y curtosis.
4. Elaborar histogramas con curvas de densidad KDE y diagramas de caja (*boxplots*) comparativos. Interpretar la dispersión y la presencia de sesgo.

Bloque 2: Distribuciones de Muestreo y Teorema Central del Límite

1. Aislar la muestra global de la métrica analizada ($N \geq 400$).
2. Programar un proceso de remuestreo con reemplazo de $k = 1,000$ muestras para tamaños muestrales $n \in \{5, 15, 30, 60\}$.
3. Graficar una cuadrícula de 2×2 con las distribuciones de las medias muestrales generadas.
4. Comparar el error estándar empírico con el valor teórico $\sigma_{\bar{x}} = \frac{s}{\sqrt{n}}$ y justificar la convergencia hacia la normalidad.

Bloque 3: Estimación por Intervalos de Confianza

1. Calcular los intervalos de confianza para la media poblacional general (μ) al **90 %**, **95 %** y **99 %**. Justificar formalmente la selección de la distribución Z o t-Student.
2. Construir el intervalo de confianza del **95 %** para la diferencia de medias ($\mu_1 - \mu_2$):
   - Ejecutar la prueba de Levene (`scipy.stats.levene`) para verificar homogeneidad de varianzas.
   - Computar el intervalo adecuado (varianzas combinadas o corrección de Welch).
3. Determinar si el valor cero pertenece al intervalo ($0 \in$ IC) y explicar su impacto práctico en la comparación de ambos grupos.

Bloque 4: Teoría de Decisión en Estadística (Prueba de Hipótesis)

1. Plantear formalmente las hipótesis nula (H_0) y alternativa (H_1) contextualizadas al problema.
2. Elaborar una matriz de decisión detallando el costo operativo o técnico de incurrir en un **Error Tipo I** (α) y un **Error Tipo II** (β).
3. Fijar el nivel de significancia en $\alpha = 0,05$.
4. Ejecutar la prueba paramétrica (`scipy.stats.ttest_ind`) y reportar el estadístico calculado y el **p-value**.
5. Declarar el veredicto formal (*Rechazar* o *No Rechazar* H_0) y emitir la recomendación técnica de ingeniería resultante.

5. Estructura del Repositorio y Rúbrica de Evaluación

Estructura en GitHub:

- `data/`: Dataset original y versión depurada (`.csv`).
- `notebooks/`: Cuaderno `.ipynb` ejecutable y documentado celda a celda.
- `docs/`: Reporte final en PDF estructurado según estándares de ingeniería.

Criterio de Evaluación	**Ponderación**
Bloque 1: Limpieza, análisis descriptivo y visualizaciones KDE/Boxplot	20 %
Bloque 2: Simulación del Teorema Central del Límite y verificación de $\sigma_{\bar{x}}$	20 %
Bloque 3: Estimación por intervalos de confianza e interpretación de $0 \in$ IC	25 %
Bloque 4: Planteamiento de hipótesis, análisis de riesgos Tipo I/II y veredicto	25 %
Calidad del código (modularidad y reproducibilidad) y reporte formal	10 %